


Базовые методы оценки важности признаков в ML

Садиех Сабрина, HSE, XAI researcher



План занятия


1. Зачем нужно применять методы для интерпретации;
2. Графические методы представления влияния признака и их количественные характеристики;
3. Метод SHAP;
4. Метод LIME;
5. Анализ взаимодействия признаков.

Что такое Explainable AI (aka XAI)?

Объяснимый искусственный интеллект (XAI) – область, охватывающая фреймворки и методы, обеспечивающие возможность объяснять прогнозы, сделанные DNN или ML моделью.

Что такое Explainable AI (aka XAI)?

Объяснимый искусственный интеллект (XAI) – область, охватывающая фреймворки и методы, обеспечивающие возможность объяснять прогнозы, сделанные DNN или ML моделью.



- Хотим понять:
 1. Как модель делает конкретный прогноз (какие компоненты модели отвечают за этот прогноз)
 2. Почему модель делает именно этот прогноз (какие признаки в input или train data за это отвечают)
- Можем использовать:
 1. В дебагинге модели;
 2. Для повышения доверия (бизнеса/пользователей);
 3. В науке;

Историческая справка

1. 1970-1980-е – Expert Systems


- правила IF-THEN, прозрачная логика, легко объяснять

2. 1980-1990-е – Чёрные ящики (ML)

- нейронные сети и ансамбли, интерпретируемость теряется
- попытки делать модели с интерпретируемой структурой (GLM, GAM, MoE)

3. 1990-2000-е – Первая волна методов интерпретации

- графические методы важности признаков для ML моделей
- использование линейных/древесных моделей как компонент сетей (GAMI-NET, Neural Tree), статистики для анализа взаимодействий




Историческая справка

4. 2016–2018 – Бум XAI


- LIME, SHAP, Integrated Gradients
- рост интереса из-за «чёрных ящиков» deep learning

5. 2020-е – XAI as model biology и законодательство за XAI

- появление механистической интерпретируемости
- интеграция задачи объяснения в нормативные требования (GDPR, AI Act)



Map of Explainability Approaches



Почему появлялись и появляются новые методы

Рост сложности моделей

- от деревьев к глубоким нейронным сетям и LLM → старые методы перестают работать/быть устойчивыми

Проблема “кому объяснять”


- необходимость объяснять прогнозы в медицине, финансах и пр. – разный уровень пользователя – разные объяснения

Cost problem

- нужны дешевые и быстрые методы, особенно для больших моделей–

Интерес исследователей и адаптация к разным задачам

- понять внутренние представления модели (интерпретация как наука)
- мультимодальные модели, генеративные модели → нужны специальные подходы



Почему появлялись и появляются новые методы

Рост сложности моделей

- от деревьев к глубоким нейронным сетям и LLM → старые методы перестают работать/быть устойчивыми

Проблема "кому объяснять"

- необходимость объяснять прогнозы в медицине, финансах, гос.секторе – разный уровень пользователя – разные объяснения

Cost problem


- нужны дешевые и быстрые методы, особенно для больших моделей–


Интерес исследователей и адаптация к разным задачам

- понять внутренние представления модели (интерпретация как наука)
- мультимодальные модели, генеративные модели → нужны специальные подходы

Можно ли выделить необходимый и достаточный pipeline для XAI?

Да, этим мы и займемся.





Deep
Learning
School

Базовые
методы
интерпретации




Deep
Learning
School

Графический
анализ
изменений в
прогнозе

CPO: Ceteris Paribus Oscillations

Ceteris Paribus Oscillations – стабильность модели через “Ceteris Paribus” профили – от лат. при прочих неизменных.


Вопрос: насколько предсказания модели меняются при изменении отдельного признака j , фиксируя остальные (отсюда и название).



Реализован в:
[pyCeterisParibus](#), [dalex](#)

СРО. Ceteris Paribus Oscillations: построение

Рассмотрим объект x_i и его признак j . Зафиксируем прогноз модели $f_0(x_i)$ – прогноз при данном значении признака j . Как будет меняться прогноз модели, если мы будем "расшатывать" признак j ?



CPO. Ceteris Paribus Oscillations: построение

Далее:

1. Зафиксируем все признаки объекта x_i , кроме j ;
2. Определим упорядоченный диапазон конкретных значений признака j_i, j_2, \dots, j_m ;
3. Начнем изменять значения j в диапазоне $\{x_j^1, x_j^2, \dots, x_j^m\}$, делаем прогноз при каждом значении признака j $f(x_i^{j_k})$;
4. Строим график зависимости:

$$CPO(x_i, j) : j \mapsto f(x_i^{j_k})$$


СРО. Ceteris Paribus Oscillations: интерпретация

1. Высокий СРО:

- Признак ј сильно влияет на предсказания модели для данного объекта.
- Возможна нестабильность модели в этом диапазоне.

2. Низкий СРО:

- Модель практически не реагирует на изменения ј.
- Признак может быть малозначимым для прогноза на этом объекте.



Ceteris-paribus профили для пассажира Генри и модели случайного леса titanic_rf. [\[dalex\]](#)


CPO. Ceteris Paribus Oscillations: практические нюансы

- Требует вычисления профилей для каждого объекта
- Отсутствует обобщение
- Не эффективен для интерпретации при нелинейных взаимодействиях признаков

Individual Conditional Expectation (ICE)

ICE – визуализируют поведение модели для нескольких объектов, показывая, как предсказания изменяются при варьировании одного признака, когда остальные зафиксированы.

Вопрос: насколько предсказания модели меняются при варьировании отдельного признака j на группе объектов, фиксируя остальные (отсюда и названия).



Individual Conditional Expectation (ICE): Построение

Пусть признак j имеет m уникальных значений.

1. Рассматриваем исходный датасет X и дублируем его m раз:

$$X'_1, X'_2, \dots, X'_m$$

(как бы фиксируем все признаки, кроме одного)

2. Рассчитываем прогноз модели $f(X_i)$
3. На одном графике отображаются линии для всех объектов, демонстрируя их индивидуальные профили.

ICE. Individual Conditional Expectation: интерпретация


Полезно красить линии под группы данных.

Разные наклоны линий:

Взаимодействие модели с объектами или значимая нелинейность.

Сходящиеся линии: Признак действует одинаково для всех объектов.

Шум: Разнообразные профили могут указывать на переобучение или недообучение модели.



car_age and car_type


ICE. Individual Conditional Expectation: практические нюансы

- Чуть более оптимальная версия СРО;
- Встроен в sklearn (и легко реализовать руками).
- Отсутствует обобщение – анализ каждого признака отдельно.
- Неприятен для восприятия и донесения информации при нелинейных взаимодействиях и на слишком большом количестве объектов.

Partial Dependence Plot (PDP)

PDP – показывает, как среднее предсказание модели меняется в зависимости от значений одного или нескольких признаков.


Глобальная интерпретация, усредняющая поведение модели по всему датасету.



Матожидание по
ICE!


Partial Dependence Plot (PDP): интерпретация

- **Плоская линия:** Признак не влияет на предсказание.
- **Наклон и кривизна:** характер зависимости предсказаний от признака. Например, растущий PDP указывает на положительное влияние признака.



PDP. Partial Dependence Plot: практические нюансы

- Убирает из виду индивидуальное влияние \Rightarrow ICE, как пара
- Игнорирует взаимодействия признаков (в одномерном построении, можно использовать двумерное)
- Не валидный метод для линейных моделей – лучше использовать анализ весов.
- Встроен в sklearn и реализован в pdpbox






[Источник](#)

Accumulated Local Effects (ALE)

ALE – оценивает влияние признаков на предсказания модели, но устраняет влияние коррелированных признаков и взаимодействий.

Это достигается путем локального анализа изменений предсказания.

[Источник](#)



ALE: построение

пусть

- $f(x)$: предсказания модели.
- F : интересующие нас признаки
- S_j : все остальные признаки, кроме F .
- Разделение значений F на интервалы: $[x_F^{(k)}, x_F^{(k+1)}]$, где $k = 1, 2, \dots, K - 1$.
- K – общее число интервалов
- n число наблюдений на наборе, для которого строим объяснение

ALE: построение

Тогда ALE :

$$f_{F,ALE} = \sum_{k=1}^K \frac{1}{|x \in N_j(k)|} \sum_{|x \in N_j(k)|} [f(x_j^{(k+1)}, S_j) - f(x_j^{(k)}, S_j)]$$

где F интересующий нас признак, $N_j(k)$ количество наблюдений, попавших в интервал с номером k , а значения в скобках — прогнозы модели при замене признака на нижнюю и верхнюю границы интервала соответственно.

ALE: построение


1. Выбрать интересующий признак F
2. Разделить диапазон изменения признака на интервалы $[x_F^{(k)}, x_F^{(k+1)}]$, где $k = 1, 2, \dots, K - 1$.
3. Для каждого интервала:
 - а) Заменить признак на значение нижней границы интервала и рассчитать прогнозы модели $f(x_F^{(k)}, S_j)$
 - б) Заменить признак на значение верхней границы интервала и рассчитать прогнозы модели $f(x_F^{(k+1)}, S_j)$
 - в) Усреднить разницу в прогнозах между (а) и (б) согласно количеству объектов в интервале.
4. Суммировать эффекты по всем интервалам и далее усреднить полученный эффект по наблюдениям:

$$f_{F,centeredALE} = f_{F,ALE} - \frac{1}{n} \sum_{k=1}^K N_j(k) f_{F,ALE}$$

Шаги "а", "б" – являются компонентами **эффекта**, а шаг "в" – **локальности**.


Accumulated Local Effects (ALE): интерпретация

- Показывает среднюю динамику изменения предсказания модели.
- В отличие от PDP, не искажает зависимости, вызванные корреляцией признаков.



Accumulated Local Effects (ALE): практические нюансы

- важно аккуратно выбрать число интервалов (bins) и анализировать их вместе с доверительными интервалами
 - слишком мало → сглаживание, потеря деталей
 - слишком много → шум
- масштаб признака влияет на график → стоит нормировать
- для категориальных признаков не валиден
- из-за линейности внутри интервалов может исказить нелинейности



Deep
Learning
School

Анализ
важности
признаков при
помощи
статистик

PDP-based feature importance

Наивный подход получения важности признака – оценка дисперсии прогноза при изменении признака

Чувствительна к диапазону значений (необходимо масштабирование)

Для категориальных признаков нормировка – эвристика

Не учитывает взаимодействия при оценке

$$\sqrt{\left(\frac{1}{k-1} \sum_{i=1}^k (f(x_{1i}) - \frac{1}{k} \sum_{i=1}^k f(x_{1i}))^2 \right)}$$

$$\frac{\max_i(f(x_{1i})) - \min_i(f(x_{1i}))}{4}$$


categorical and continuous pdp-based ft importance
1i — уникальные наблюдения, содержащие признак i

Permutation importances

Permutation importances – оценка потери качества модели при случайной перестановке значений признака.


Чем сильнее амплитуда изменений метрики качества или прогноза – тем важнее признак

Height at age 20 (cm)	Height at age 10 (cm)
182	155
175	147
...	...
156	142
153	130



Permutation importances

Пусть $a(x)$ модель, обученная на множестве признаков $F = f_1, f_2, \dots, f_n$, e_{orig} – ошибка модели на тестовом наборе данных. Зафиксируем признак f_i .




Permutation importances

Для этого признака:

- случайным образом переставим его значения в тестовом наборе данных;
- вычислим прогноз модели на тестовых данных с перестановкой;
- оценим ошибку модели на наборе данных с перетасовкой e_{perm}
- оценим важность признака как разность $e_{orig} - e_{perm}$ или частное $\frac{e_{perm}}{e_{orig}}$

Данный алгоритм повторяется со всеми признаками и далее они сортируются по убыванию важности.




Таким образом важность признака $f_i = e_{orig} - \frac{1}{K} \sum_{k=1}^K e_{perm,k}$, где K – число перестановок.

Permutation importances.

Практические особенности


- метод, применимый к любым моделям
- читывает нелинейности и взаимодействия признаков
- даёт глобальную важность – для всех примеров из датасета сразу
- не справляется с корреляцией признаков важность распределяется между ними
- вычислительно дорог – сложность $O(p*n!)$, где p – число признаков, n – число перестановок
- чувствителен к случайности – важно использовать несколько повторов и доверительные интервалы
- использовать на валидационной/тестовой выборке, а не на train



Permutation importances.

Практические особенности


- вычислительно дорог – сложность $O(p*n)$, где p – число признаков, n – число перестановок
- чувствителен к случайности – важно использовать несколько повторов и доверительные интервалы
- использовать на валидационной/тестовой выборке, а не на train



SHAP

Семейство методов, основанных на Shapley Values (значения Шепли) – концепции из теории игр, предложенная Ллойдом Шепли в 1953г..
Изначально были предложены в задаче распределения вознаграждений среди участников игры.


Как метод оценки важности признаков предложены в 2017 году в статье “A Unified Approach to Interpreting Model Predictions”. В настоящее время – один из наиболее часто используемых методов.



SHAP: построение

Пусть определены:

- N – множество игроков, играющих в игру, $|N| = n$
- S – произвольное подмножество N (коалиция)
- $v(S)$ – функция выигрыша, характеризующая успешность игры с участием игроков из S




SHAP: построение

Алгоритм:

Чтобы учесть вклад конкретного игрока $i \in N$ в коалицию S нужно:

1. рассмотреть все возможные подмножества без игрока i и посчитать прогноз без них
2. рассмотреть все возможные подмножества с игроком и посчитать прогноз после добавления игрока i
3. получить разность вычисленных значений




SHAP: построение

Согласно требуемым действиям, значение Шепли для игрока i можно определить как:

$$Sh(v)_i = \sum_{S \subseteq N \setminus i} \frac{|S|!(n - |S| - 1)!}{n!} \Delta(i, S)$$

где:

- $\Delta(i, S) = v(S \cup i) - v(S)$ прирост от добавления игрока i в коалицию S ;
- S произвольная коалиция из множества $N \setminus i$
- $v(S)$ – характеристическая функция игры, с участием коалиции S
- $\frac{|S|!(n - |S| - 1)!}{n!}$ нормирующий множитель для каждого слагаемого



SHAP: аксиоматика


1. **Локальная точность** – прогноз модели может быть разложен на комбинацию значений Шепли и признаков
2. **Аксиома болвана** – если признак отсутствует, то его вклад всегда нулевой
3. **Согласованность** – если при дообучении вклад признака в модель увеличился, а вклад остальных признаков не уменьшился, то значение Шепли тоже не уменьшается

$$f(x) = \phi_0 + \sum_{i=1}^M \phi_i x_i$$

If $x_i \in \{0, \emptyset\}$ then $\phi_i = 0$


$$f'(S \cup \{i\}) - f'(S) \geq f(S \cup \{i\}) - f(S)$$

$$\forall S \subseteq F \setminus \{i\} \Rightarrow \phi_i(f') \geq \phi_i(f)$$




SHAP: практические особенности

- Дорого вычислять: 2^r число подмножеств – нужны аппроксимации
 - KernelSHAP (модель-агностичный)
 - TreeSHAP (для древесных моделей)
- Устойчивее к коррелированным признакам, чем Permutation Importance
- При сильной мультиколлинеарности интерпретация может быть сложной (SHAP делит вклад между признаками)



SHAP: практические особенности

- Тонкости с категориальными признаками
- Можно получать как локальные (для одного предсказания), так и глобальные объяснения (усреднённые SHAP)
- Для моделей с высокой размерностью признакового пространства вычислительно тяжёлый




Explainable AI: SHAP


TheAiEdge.io




Kernel SHAP: LIME with Shapley Smoothing Kernel



Tree SHAP: Shapley estimates for Trees



Deep SHAP: Shapley estimates for Neural Networks






Deep
Learning
School

Анализ
важности
признаков при
помощи
суррогатных
моделей

LIME

LIME – Local interpretable model-agnostic explanation – модель-независимый алгоритм объяснения модели, основанный на построении локальной интерпретируемой модели, которая аппроксимирует сложную модель вблизи конкретного прогноза.

Был предложен в 2016 году в статье ""Why Should I Trust You?"". Также один из наиболее используемых в настоящее время.



LIME: постановка

$f(x)$ — модель-черный ящик

$g(z)$ — интерпретируемая модель


$$\xi(x) = \operatorname{argmin}_{g \in G} L(f, g, \pi_x) + \Omega(g)$$

L — расстояние между прогнозами моделей (MSE)

π_x — окрестность наблюдения x

Ω — регуляризация

LIME with Tabular data




LIME: построение


1. Генерируем синтетические точки рядом с x (perturbations)
2. Считаем предсказания f для этих точек
3. Взвешиваем их по близости к x
4. Обучаем простую модель g (обычно линейную)
5. Коэффициенты g принимаем за локальные важности признаков

Explainable AI: LIME


LIME with Tabular data



LIME with Text data




LIME with Image data



LIME: практические тонкости

- Локальная интерпретируемость (фокус на одном прогнозе)
- Модель-независимый метод
- Важно следить за стабильностью – выбор ширины окрестности влияет на результат
- Не учитывает нелокальные взаимодействия признаков
- Для дискретных и текстовых данных требуется аккуратная генерация perturbations





Спасибо за внимание!

tg: @sabrina_sadiekh,
[jdata_blog](#)

Садиех Сабрина

HSE, XAI researcher

